

# Uma Ferramenta para Apoiar a Seleção de Instrumentos de Avaliação de Chatbots Educacionais

Mariana Almeida Faustino  
Universidade Tecnológica Federal do  
Paraná, UTFPR  
Curitiba, Brasil  
marianaafaustino@alunos.utfpr.edu.br

Gabriel Felipe Jess Meira  
Pontifícia Universidade Católica do  
Paraná, PUCPR  
Curitiba, Brasil  
gabrieljfmeira@gmail.com

Silvana Morita Melo  
Universidade Federal da Grande  
Dourados, UFGD  
Mato Grosso do Sul, Brasil  
silvanamelo@ufgd.edu.br

Leo Natan Paschoal  
Pontifícia Universidade Católica do  
Paraná, PUCPR  
Curitiba, Brasil  
leo.paschoal@pucpr.br

Pedro Henrique Dias Valle  
Universidade de São Paulo, USP  
São Paulo, Brasil  
pedrohenriquevalle@usp.br

## Resumo

Os chatbots educacionais têm sido amplamente utilizados para apoiar processos de ensino e aprendizagem, tornando fundamental a avaliação desses sistemas para assegurar sua qualidade e efetividade. Entretanto, a seleção de instrumentos de avaliação ainda representa um desafio para avaliadores, devido à diversidade de instrumentos e artefatos disponíveis e à dispersão de informações na literatura científica. Nesse sentido, este trabalho apresenta uma ferramenta web destinada a apoiar a seleção de instrumentos e artefatos para avaliação de chatbots educacionais. A ferramenta foi desenvolvida com base nos instrumentos e artefatos identificados em um mapeamento sistemático da literatura e organiza os metadados dos instrumentos identificados em um catálogo, permitindo sua consulta por meio de mecanismos de busca e de filtragem. Além disso, disponibiliza informações estruturadas sobre cada instrumento, incluindo descrição, atributos de qualidade, modalidade de comunicação, idiomas disponíveis e um link de acesso ao instrumento. Como principal contribuição, a ferramenta centraliza as informações sobre instrumentos de avaliação em um único ambiente, apoiando pesquisadores na identificação e seleção de alternativas adequadas a diferentes cenários de avaliação de chatbots educacionais.

## Palavras-chave

Chatbots, Agentes Conversacionais, Avaliação de Software

## 1 Introdução

Nos últimos anos, a aplicação de agentes conversacionais, ou chatbots, no cenário educacional tem crescido substancialmente. Conforme argumentam Winkler and Söllner [15], esses sistemas de software têm demonstrado elevado potencial ao evoluírem de sistemas básicos de resposta a perguntas frequentes a tutores dinâmicos, capazes de apoiar ativamente os processos de ensino e aprendizagem. Com a adoção acelerada, a complexidade inerente a essas ferramentas também aumentou. No entanto, como observam Kuhail et al. [5], embora o desenvolvimento de chatbots educacionais esteja em rápida expansão, os métodos utilizados para avaliá-los permanecem altamente inconsistentes. Os autores destacam que muitos

estudos ainda recorrem a métricas variadas ou instrumentos desenvolvidos especificamente para um único contexto, o que dificulta a comparação sistemática da qualidade de software e da eficácia pedagógica entre diferentes sistemas.

De acordo com Radziwill and Benton [13], a avaliação da qualidade de chatbots envolve múltiplas dimensões, abrangendo tanto atributos tradicionais da engenharia de software quanto aspectos específicos da interação entre usuários e chatbots, como a qualidade do diálogo, a compreensão das entradas e a adequação das respostas. Contudo, a área ainda carece de um consenso metodológico sólido. Em seu levantamento sobre métodos de avaliação, Maroengsit et al. [6] destacam a ausência de um padrão universalmente aceito. De forma semelhante, Debets et al. [3] observaram que, embora apresentem resultados promissores, as avaliações permanecem predominantemente baseadas em fatores perceptivos e utilizam critérios bastante diversos.

Após a observação de ausência de consenso metodológico, diversos estudos passaram a investigar como os chatbots educacionais vêm sendo avaliados [10]. Em particular, Kuhail et al. [5] identificaram uma ampla variedade de critérios e instrumentos empregados na literatura, abrangendo dimensões técnicas, pedagógicas e relacionadas à experiência do usuário, evidenciando elevada heterogeneidade nas abordagens de avaliação. De forma semelhante, Debets et al. [3] observaram que, embora os chatbots educacionais apresentem resultados promissores em diferentes contextos de ensino, suas avaliações permanecem predominantemente baseadas em fatores perceptivos e utilizam critérios bastante diversos, o que dificulta a comparação entre os estudos.

Para aprofundar esse cenário, Faustino et al. [4] realizaram um mapeamento sistemático da literatura para identificar os instrumentos empregados na avaliação de chatbots educacionais, catalogando um acervo robusto de 41 estudos primários. Os resultados evidenciaram uma forte concentração de avaliações voltadas à qualidade em uso, especialmente em atributos como satisfação e aceitação, enquanto características relacionadas à qualidade do produto permanecem pouco exploradas. Mais criticamente, os autores verificaram a ampla utilização de instrumentos criados para contextos isolados, classificando a literatura mapeada em 27 instrumentos com validação prévia e 14 modelos desenvolvidos de forma estritamente *ad hoc*. Essa dispersão e a recorrente adaptação de instrumentos, sem

evidências de revalidação psicométrica, comprometem a comparabilidade dos resultados e a consolidação de evidências na área.

Embora a literatura disponha de um número crescente de instrumentos e artefatos para a avaliação de chatbots educacionais, a diversidade de objetivos, atributos de qualidade, contextos de aplicação e níveis de validação dificulta sua utilização na prática. Como essas informações estão distribuídas em diferentes estudos, avaliadores frequentemente precisam analisar diversas publicações para identificar quais instrumentos são mais adequados às características da avaliação que pretendem realizar. Esse processo demanda tempo, dificulta a comparação entre alternativas e pode resultar na seleção de instrumentos incompatíveis com os objetivos da avaliação.

Nesse contexto, uma ferramenta que reúna informações estruturadas sobre instrumentos e artefatos de avaliação de chatbots educacionais pode apoiar pesquisadores no processo de avaliação, facilitando a identificação de instrumentos compatíveis com seus objetivos, com os atributos de qualidade avaliados, com o tipo de evidência produzida e com o contexto de aplicação. Ao centralizar esses metadados em um único ambiente, a ferramenta pode reduzir o esforço na seleção de instrumentos, favorecer a reutilização de instrumentos e artefatos de avaliação previamente documentados e contribuir para uma condução mais sistemática e consistente das avaliações.

Com base nessa motivação, este trabalho apresenta uma ferramenta web desenvolvida para apoiar a avaliação de chatbots educacionais por meio da organização e da disponibilização de metadados sobre instrumentos e artefatos de avaliação identificados na literatura. A ferramenta permite que pesquisadores consultem e comparem instrumentos com base em diferentes critérios, apoiando a seleção dos mais adequados aos objetivos de suas avaliações. A seleção de instrumentos constitui etapa central do planejamento de estudos experimentais em Engenharia de Software [14], impactando a validade de constructo e a comparabilidade de resultados obtidos entre diferentes pesquisas. Inserida no contexto da Engenharia de Software Experimental, a proposta aborda a avaliação de bots sob uma perspectiva de Engenharia de Software, contribuindo para a realização de estudos mais estruturados, sistemáticos e reprodutíveis e para a obtenção de evidências experimentais sobre o desempenho e a qualidade de chatbots aplicados à educação.

## 2 Trabalhos Relacionados

Com o objetivo de contextualizar a proposta deste trabalho, esta seção apresenta iniciativas da literatura sobre a avaliação de chatbots educacionais. Foram selecionados estudos que propõem *frameworks*, modelos, métricas e outras contribuições para apoiar esse processo. A análise desses trabalhos permite identificar suas principais características e evidenciar a oportunidade de desenvolver uma ferramenta voltada à organização e à seleção de instrumentos de avaliação.

Qiu et al. [12] propõem um *framework* baseado em *learning analytics* para avaliar chatbots de IA generativa em contextos educacionais, integrando múltiplas fontes de evidência — desempenho dos estudantes, interações com o chatbot, engajamento e percepções dos usuários — para mitigar a fragmentação das abordagens existentes. A proposta foi demonstrada em um estudo quase experimental

com um chatbot de diálogos socráticos, oferecendo aos pesquisadores uma estrutura integrada para avaliações fundamentadas em diferentes dimensões da aprendizagem.

Olla et al. [8] propõem um *framework* para avaliar chatbots em simulações educacionais de enfermagem, organizado em duas fases: avaliação do projeto instrucional e da qualidade dos *prompts*, e avaliação do desempenho do agente durante a interação. Contempla critérios como credibilidade, alinhamento pedagógico, transparência, personalização, experiência do usuário e resultados de aprendizagem, aplicados automaticamente por meio de um protótipo, o Eval-Bot. O trabalho propõe um modelo sistemático que enfatiza a qualidade dos *prompts* e o desempenho do chatbot.

Paschoal [9] propõe um *framework* para apoiar o processo de avaliação experimental de sistemas conversacionais pedagógicos, com o objetivo de sistematizar o planejamento, a condução e o relato de estudos experimentais nessa área. A proposta prevê a construção de um conjunto de artefatos composto por um vocabulário comum para experimentação, um corpo de conhecimento sobre variáveis, métricas e instrumentos de avaliação, diretrizes para a identificação de ameaças à validade, um guia para a condução de experimentos e um ambiente computacional de apoio ao gerenciamento das avaliações. Segundo o autor, esses artefatos visam reduzir a heterogeneidade observada na condução de estudos experimentais e fornecer suporte metodológico aos pesquisadores no processo de avaliação de sistemas conversacionais pedagógicos.

Alabbas and Alomar [1] propõem uma métrica para avaliar a experiência do usuário em chatbots educacionais, buscando superar as limitações de abordagens que avaliam isoladamente aspectos como usabilidade, engajamento e desempenho. A proposta integra medidas de usabilidade obtidas por meio do *Chatbot Usability Questionnaire* (CUQ), indicadores de engajamento provenientes da *User Engagement Scale – Short Form* (UES-SF) e métricas objetivas de desempenho, como tempo de resposta e taxa de erros. Para combinar essas diferentes dimensões, os autores empregam a técnica de *Principal Component Analysis* (PCA), obtendo uma métrica ponderada que permite uma avaliação mais abrangente da experiência do usuário. A proposta foi validada por meio de um estudo experimental que comparou diferentes modos de interação de um chatbot educacional, demonstrando o potencial da métrica para apoiar avaliações mais consistentes da experiência de uso em ambientes educacionais.

Wollny et al. [16] propõem uma matriz de classificação para avaliações de chatbots educacionais, organizada em critérios (ex.: sucesso da aprendizagem, aceitação, motivação, usabilidade), métodos (*Wizard of Oz*, estudos de laboratório e de campo, validações técnicas) e instrumentos (questionários, entrevistas, transcrições, logs) identificados por meio de revisão sistemática. O estudo oferece uma visão estruturada dessas abordagens, servindo de referência para a seleção de critérios, métodos e instrumentos em avaliações futuras.

Petrillo et al. [11] propõem um *framework* para o desenvolvimento e a avaliação do chatbot universitário ALES, integrando normas como ISO/IEC 25010, TRL, CMMI e GQM em seis dimensões (e, g, acurácia, usabilidade, desempenho, confiabilidade, ética e impacto educacional) organizadas em um modelo de maturidade de cinco níveis. A proposta orienta a evolução e a adoção gradual de chatbots em ambientes institucionais.

**Tabela 1: Comparação entre os trabalhos relacionados e a proposta deste estudo.**

| Estudos                | Framework de avaliação | Organiza instrumentos | Busca/ Filtros | Recomenda instrumentos | Ferramenta Web |
|------------------------|------------------------|-----------------------|----------------|------------------------|----------------|
| Qiu et al. [12]        | ✓                      | -                     | -              | -                      | -              |
| Olla et al. [8]        | ✓                      | -                     | -              | -                      | ✓              |
| Paschoal [9]           | ✓                      | ✓                     | -              | -                      | -              |
| Alabbas and Alomar [1] | -                      | -                     | -              | -                      | -              |
| Wollny et al. [16]     | ✓                      | ✓                     | -              | -                      | -              |
| Petrillo et al. [11]   | ✓                      | -                     | -              | -                      | -              |
| UXNator [7]            | -                      | ✓                     | ✓              | ✓                      | ✓              |
| UX4ALL [2]             | -                      | ✓                     | ✓              | -                      | ✓              |
| <b>Este trabalho</b>   | -                      | ✓                     | ✓              | ✓                      | ✓              |

Na área de UX, o UXNator [7] recomenda métodos de avaliação a partir de critérios informados pelo usuário, e o UX4ALL [2] organiza um repositório de métodos de UX. Ambos, contudo, tratam métodos de avaliação de UX de forma genérica, sem foco em chatbots educacionais nem estruturação por atributos de qualidade de software (ISO/IEC 25010) ou modalidade de comunicação, dimensões centrais à proposta deste trabalho.

A Tabela 1 evidencia que a maior parte das iniciativas semelhantes concentra-se na proposição de *frameworks*, métricas ou diretrizes para conduzir avaliações de chatbots educacionais, sem disponibilizar um ambiente que centralize e recupere instrumentos de forma estruturada. Exceções nesse cenário são o UXNator e o UX4ALL, que oferecem, respectivamente, recomendação e organização de métodos de avaliação de UX; ambos, porém, tratam desses métodos de forma genérica, sem foco em chatbots educacionais nem estruturação de metadados por atributos de qualidade de software (ISO/IEC 25010) ou modalidade de comunicação. Nesse contexto, a ferramenta proposta neste trabalho complementa as iniciativas existentes ao combinar a especificidade temática do domínio de chatbots educacionais com um catálogo web de instrumentos organizado segundo metadados estruturados e relevantes à Engenharia de Software, contribuindo para tornar o processo de seleção mais sistemático e fundamentado.

### 3 Descrição da Ferramenta

A ferramenta proposta foi desenvolvida para apoiar avaliadores no processo de seleção de instrumentos e artefatos destinados à avaliação de chatbots educacionais. Sua principal contribuição consiste na organização dos metadados dos instrumentos identificados no mapeamento sistemático conduzido por Faustino et al. [4], disponibilizando essas informações em um ambiente web que apoia a consulta e a exploração do conhecimento consolidado na literatura. Dessa forma, a ferramenta atua como um catálogo, permitindo que os instrumentos sejam recuperados por características relevantes ao planejamento da avaliação, como atributos de qualidade, modalidade de comunicação do chatbot avaliado, idioma do instrumento de avaliação e evidências de validação.

Diferentemente da consulta convencional à literatura, em que o pesquisador precisa analisar individualmente diferentes publicações para identificar instrumentos compatíveis com seu objetivo, a ferramenta centraliza essas informações em um único ambiente e as apresenta de forma padronizada. Cada instrumento é representado por um conjunto estruturado de metadados, permitindo consultar rapidamente suas principais características, sem necessidade

de acessar o estudo que propõe o instrumento de avaliação. Essa organização favorece a reutilização de instrumentos previamente empregados em pesquisas, reduz o esforço necessário para localizar informações relevantes e torna o processo de seleção mais sistemático, transparente e fundamentado.

Além de apoiar a recuperação das informações, visa facilitar a evolução contínua do catálogo de instrumentos. Para isso, permite que novos instrumentos sejam recomendados pelos usuários e, posteriormente, analisados por administradores antes de sua incorporação ao catálogo. Essa estratégia busca manter o catálogo atualizado à medida que novos instrumentos são desenvolvidos e publicados, preservando a consistência e a qualidade das informações disponibilizadas.

#### 3.1 Funcionalidades da Ferramenta

As funcionalidades da ferramenta foram definidas para apoiar as principais atividades realizadas durante o planejamento da avaliação de chatbots educacionais, abrangendo desde a localização de instrumentos até a consulta de informações necessárias para sua seleção. Em vez de disponibilizar apenas um catálogo estático, a ferramenta oferece mecanismos que permitem recuperar instrumentos segundo diferentes critérios de pesquisa e acessar seus metadados de forma estruturada, proporcionando maior agilidade na identificação de alternativas compatíveis com distintos cenários de avaliação.

A consulta aos instrumentos é realizada por meio de mecanismos de busca textual e filtragem, permitindo que os resultados sejam refinados conforme características específicas dos instrumentos. Para cada resultado recuperado, a ferramenta disponibiliza uma ficha técnica contendo os metadados apresentados na Tabela 2, incluindo autores, descrição, categoria, atributos de qualidade contemplados, modalidade de comunicação, idiomas disponíveis e link de acesso ao instrumento original. Dessa forma, espera-se que o usuário consiga visualizar mais rapidamente os principais metadados e características do instrumento antes de consultar a publicação correspondente — hipótese a ser avaliada empiricamente em trabalhos futuros (Seção 5).

Para a definição dos metadados, utilizou-se como referência o padrão Learning Object Metadata (LOM) (IEEE 1484.12.1)<sup>1</sup>, amplamente empregado para descrever e organizar recursos educacionais por meio de um conjunto padronizado de metadados. Optou-se pelo LOM em detrimento de padrões genéricos, como o Dublin Core, por sua maior granularidade para recursos com finalidade pedagógica

<sup>1</sup>Mais informações disponíveis em: <https://ieeexplore.ieee.org/document/1032843>.

**Tabela 2: Principais funcionalidades da ferramenta**

| Funcionalidade    | Descrição                                                                                                                                                                            |
|-------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Busca por nome    | Localiza instrumentos pelo nome em ordem alfabética.                                                                                                                                 |
| Busca por filtros | Filtra instrumentos por atributos de qualidade, modalidade de comunicação e idioma.                                                                                                  |
| Visualização      | Exibe a ficha técnica do instrumento, incluindo título, autores, descrição, categoria, atributos de qualidade, modalidade de comunicação, idioma e link para o instrumento original. |
| Recomendação      | Permite recomendar novos instrumentos para inclusão no catálogo.                                                                                                                     |

e por já contemplar categorias diretamente aplicáveis ao domínio da ferramenta, como tipo de recurso educacional e modalidade de interatividade. Embora o LOM tenha sido concebido para objetos de aprendizagem, sua estrutura serviu como base para a organização das informações dos instrumentos de avaliação, sendo adaptada às características específicas do domínio de chatbots educacionais. A Tabela 3 apresenta os principais metadados considerados na ferramenta.

**Tabela 3: Metadados do catálogo baseados no IEEE LOM**

| Metadado                   | Identificação LOM                       | Descrição                                                                 |
|----------------------------|-----------------------------------------|---------------------------------------------------------------------------|
| Título                     | General.Title (1.2)                     | Nome oficial dado ao objeto de aprendizagem para identificação primária.  |
| Autores                    | LifeCycle.Contribute (2.3)              | Define as entidades (pessoas/orgs) e seu papel na criação (ex: Author).   |
| Idioma                     | General.Language (1.3)                  | Idioma principal utilizado no conteúdo do recurso para o usuário final.   |
| Descrição                  | General.Description (1.4)               | Resumo textual do conteúdo do objeto, facilitando a busca e seleção.      |
| Link do instrumento        | Technical.Location (4.3)                | Endereço eletrônico (URL) onde o objeto pode ser acessado.                |
| Instrumento                | Educational.Learning-ResourceType (5.2) | Classifica a natureza do recurso (ex: questionário, escala).              |
| Descrição do instrumento   | Educational.Description (5.10)          | Explicação de como o recurso deve ser usado sob a perspectiva pedagógica. |
| Categoria                  | Classification.Taxon-Path (9.2)         | Usado para situar o objeto em uma taxonomia ou área específica.           |
| Atributos de qualidade     | Annotation (8)                          | Espaço para comentários sobre a qualidade ou observações de uso.          |
| Atributos                  | General.Keyword (1.5)                   | Palavras-chave que descrevem temas centrais e características gerais.     |
| Modalidades de comunicação | Educational.InteractivityType (5.1)     | Define se a comunicação é feita por texto ou de forma multimodal.         |

As funcionalidades apresentadas na Tabela 2 foram organizadas para apoiar diferentes etapas do processo de seleção de instrumentos, desde sua localização até a consulta detalhada de seus metadados. Em conjunto, essas funcionalidades contribuem para tornar o processo de identificação e utilização de instrumentos mais

eficiente, reduzindo a necessidade de consultas repetidas à literatura e favorecendo a reutilização do conhecimento previamente produzido.

### 3.2 Requisitos da Ferramenta

Na Engenharia de Software, os requisitos funcionais especificam os serviços que um sistema deve fornecer e o comportamento esperado em resposta às interações dos usuários [14]. A definição desses requisitos constitui uma etapa fundamental do desenvolvimento de software, pois estabelece uma especificação clara das funcionalidades a serem implementadas e fornece subsídios para as atividades de projeto, implementação e validação do sistema.

Considerando esse princípio, as funcionalidades propostas para a ferramenta foram detalhadas por meio dos requisitos funcionais apresentados na Tabela 4. Os requisitos foram definidos com base no mapeamento sistemático Faustino et al. [4] sem elicitação formal com usuários finais nesta etapa; a validação com avaliadores está prevista como trabalho futuro (Seção 5).

**Tabela 4: Principais requisitos funcionais da ferramenta**

| ID   | Requisito Funcional                                                                                                                               |
|------|---------------------------------------------------------------------------------------------------------------------------------------------------|
| RF01 | O sistema deve permitir consultar o catálogo de instrumentos de avaliação de chatbots educacionais.                                               |
| RF02 | O sistema deve permitir pesquisar instrumentos por nome e aplicar filtros baseados em atributos de qualidade, idioma e modalidade de comunicação. |
| RF03 | O sistema deve apresentar os instrumentos encontrados em ordem alfabética.                                                                        |
| RF04 | O sistema deve informar quando não houver resultados para os critérios de busca informados.                                                       |
| RF05 | O sistema deve exibir a ficha técnica do instrumento, incluindo seus principais metadados e o link para o instrumento original.                   |
| RF06 | O sistema deve permitir o gerenciamento (cadastro, edição e remoção) dos instrumentos por administradores.                                        |
| RF07 | O sistema deve permitir o cadastro de usuários administradores.                                                                                   |
| RF08 | O sistema deve permitir que usuários recomendem novos instrumentos para o catálogo.                                                               |
| RF09 | O sistema deve permitir que administradores aprovem ou rejeitem recomendações de novos instrumentos.                                              |

Os requisitos funcionais foram definidos para responder à dispersão de instrumentos na literatura e à necessidade de atualização contínua do catálogo, sendo agrupados em dois conjuntos complementares de acordo com o perfil de utilização da ferramenta. Os requisitos RF01 a RF06 contemplam as funcionalidades destinadas aos avaliadores, abrangendo a consulta ao catálogo, a pesquisa por diferentes critérios, a visualização da ficha técnica dos instrumentos e a recomendação de novos registros para inclusão no catálogo. Por sua vez, os requisitos RF07 a RF09 correspondem às funcionalidades administrativas, responsáveis pelo gerenciamento dos instrumentos cadastrados, pela administração dos usuários e pela validação das recomendações submetidas. Essa organização favorece a separação de responsabilidades entre os perfis de usuários e contribui para a definição de mecanismos de controle de acesso e manutenção do catálogo.

### 3.3 Arquitetura

A arquitetura da ferramenta foi definida com o objetivo de atender aos requisitos funcionais apresentados na seção anterior, priorizando atributos de qualidade como manutenibilidade, modularidade, escalabilidade e segurança. Considerando que o catálogo de instrumentos deverá evoluir continuamente com a incorporação de novos registros e funcionalidades, adotou-se uma arquitetura em camadas capaz de promover a separação de responsabilidades entre os componentes da aplicação, reduzindo o acoplamento entre suas partes e facilitando atividades de manutenção e evolução do sistema.

A Figura 1 apresenta a arquitetura da ferramenta por meio do diagrama C4 no nível de contêineres. O sistema é composto por uma aplicação web, responsável pela interação com os usuários e pelo processamento das regras de negócio, e por um banco de dados relacional, utilizado para armazenar os metadados dos instrumentos, as informações dos usuários e as recomendações submetidas ao catálogo. Os usuários interagem com a aplicação por meio de requisições HTTP, enquanto a aplicação realiza operações de consulta e persistência no banco de dados.




Figura 1: Diagrama de contêiner (C4 model) da ferramenta.

**3.3.1 Organização em Camadas.** A arquitetura da ferramenta foi organizada em camadas, separando os componentes responsáveis pela apresentação, processamento das regras de negócio, persistência dos dados e gerenciamento das requisições. Essa organização reduz o acoplamento entre os componentes da aplicação e favorece sua manutenção e evolução ao longo do tempo.

A camada de apresentação é responsável pela interação com os usuários, disponibilizando as interfaces para consulta ao catálogo, visualização das fichas técnicas dos instrumentos, recomendação de novos registros e gerenciamento administrativo. Essa camada

concentra exclusivamente aspectos relacionados à interação com o usuário, mantendo-se desacoplada das regras de negócio da aplicação.

A camada de serviços implementa as regras responsáveis pelo funcionamento da ferramenta, incluindo a recuperação dos instrumentos segundo diferentes critérios de busca, o processamento das recomendações submetidas pelos usuários, o gerenciamento dos perfis de acesso e a validação das operações realizadas sobre o catálogo. Dessa forma, toda a lógica da aplicação permanece centralizada em um único componente, favorecendo sua reutilização e testabilidade.

Por sua vez, a camada de persistência é responsável pelo gerenciamento dos dados armazenados pela aplicação. Essa camada encapsula o acesso ao banco de dados, abstraindo detalhes de armazenamento das demais camadas da arquitetura e permitindo que alterações na tecnologia de persistência possam ser realizadas com impacto mínimo sobre a lógica da aplicação.

**3.3.2 Tecnologias Adotadas.** Após a definição dos requisitos funcionais e da arquitetura da ferramenta, foram selecionadas as tecnologias utilizadas em sua implementação. A escolha priorizou soluções amplamente empregadas no desenvolvimento de aplicações web modernas, capazes de favorecer a manutenibilidade, a escalabilidade e a integração entre os diferentes componentes da aplicação. Além disso, buscou-se utilizar tecnologias consolidadas, com ampla documentação e comunidade ativa, reduzindo a complexidade de manutenção e possibilitando futuras evoluções da ferramenta.

A aplicação foi desenvolvida utilizando o *framework* Next.js<sup>2</sup>, que oferece suporte à renderização híbrida entre cliente e servidor e permite a construção de aplicações web com boa organização estrutural e desempenho. Essa característica mostrou-se adequada ao contexto da ferramenta, cuja principal operação consiste na consulta e recuperação de informações armazenadas em um catálogo de instrumentos de avaliação.

Para a persistência dos dados foi adotado um banco de dados relacional PostgreSQL<sup>3</sup>, uma vez que os metadados dos instrumentos apresentam elevada estruturação e diversos relacionamentos entre entidades, como atributos de qualidade, idiomas, modalidades de comunicação, usuários e recomendações. Esse modelo facilita a realização de consultas por múltiplos critérios e garante a integridade dos dados armazenados.

A comunicação entre a interface da aplicação e a camada responsável pelo processamento das regras de negócio ocorre por meio de uma API REST, implementada por meio das rotas de API do próprio *framework* adotado, responsável pelo gerenciamento das requisições, pela validação das operações e pelo acesso aos dados persistidos. Essa separação entre interface, lógica da aplicação e persistência favorece a modularidade do sistema e reduz o acoplamento entre seus componentes.

## 4 Interfaces da Ferramenta

A interface da ferramenta foi desenvolvida para proporcionar uma interação simples e intuitiva durante o processo de seleção de instrumentos de avaliação. Seu projeto buscou organizar os metadados

<sup>2</sup>Mais informações disponíveis em: <https://nodejs.org/pt/about>.

<sup>3</sup>Mais informações disponíveis em: <https://www.postgresql.org/>.

de forma clara, permitindo que os pesquisadores localizem rapidamente os instrumentos disponíveis e consultem suas principais características. As Figuras 2 e 3 apresentam as principais interfaces do protótipo desenvolvido.

A Figura 2 apresenta a tela principal da ferramenta. O usuário pode consultar o catálogo de instrumentos por meio de busca textual ou aplicar filtros relacionados aos atributos de qualidade, modalidade de comunicação e idioma. Os resultados são apresentados em ordem alfabética e fornecem acesso à ficha técnica de cada instrumento.



**Figura 2: Protótipo da interface principal do catálogo de instrumentos de avaliação.**

A Figura 3 apresenta a interface de visualização de um instrumento. Nessa tela são disponibilizados seus principais metadados, incluindo autores, descrição, categoria, atributos de qualidade, modalidade de comunicação, idiomas disponíveis e o link para o instrumento original, apoiando o pesquisador na análise e seleção do instrumento mais adequado ao contexto de avaliação.



**Figura 3: Protótipo da ficha técnica de um instrumento selecionado pelo usuário.**

## 5 Conclusões

A crescente adoção de chatbots educacionais tem evidenciado a necessidade de avaliações mais sistemáticas e de mecanismos que apoiem avaliadores na seleção de instrumentos adequados a diferentes contextos de uso. Entretanto, a diversidade de instrumentos e artefatos descritos na literatura, aliada à dispersão dessas informações em diferentes publicações, torna esse processo complexo e demanda um esforço significativo de busca, análise e comparação.

Com o objetivo de contribuir para esse cenário, este trabalho apresentou uma ferramenta web destinada ao apoio à seleção de instrumentos e artefatos para avaliação de chatbots educacionais. A ferramenta organiza, em um único ambiente, os metadados extraídos de um mapeamento sistemático da literatura, permitindo sua consulta por meio de mecanismos de busca e filtragem, além da visualização estruturada das principais informações de cada instrumento. Também foram apresentados os requisitos funcionais, a arquitetura da solução e o protótipo da interface, evidenciando como as funcionalidades propostas apoiam o processo de identificação e seleção de instrumentos de avaliação.

Em comparação com os trabalhos relacionados, observa-se que a maior parte das pesquisas concentra-se na proposição de *frameworks*, métricas ou diretrizes para conduzir avaliações de chatbots educacionais. Em contrapartida, a ferramenta proposta busca complementar essas iniciativas ao disponibilizar um catálogo estruturado de instrumentos de avaliação, oferecendo suporte à recuperação e organização das informações necessárias ao planejamento das avaliações.

Como trabalhos futuros, pretende-se concluir a implementação da ferramenta e disponibilizá-la como um software *open-source*, ampliar continuamente o catálogo com novos instrumentos identificados na literatura sustentada pelo mecanismo de recomendação de novos instrumentos (RF08) combinado à curadoria por administradores (RF09), que preserva a qualidade das informações disponibilizadas e realizar estudos empíricos com pesquisadores para avaliar sua utilidade, usabilidade e contribuição ao processo de seleção de instrumentos para avaliação de chatbots educacionais.

## Disponibilidade de Artefatos

Este trabalho não disponibiliza artefatos.

## Agradecimentos

Os autores agradecem ao Conselho Nacional de Desenvolvimento Científico e Tecnológico, à Fundação Araucária de Apoio ao Desenvolvimento Científico e Tecnológico do Estado do Paraná, e à PROPP/UFGD pelo apoio concedido por meio do projeto SIGProj nº 322855.1174.8276.11032019.

## Referências

- [1] Abeer Alabbas and Khalid Alomar. 2025. A Weighted Composite Metric for Evaluating User Experience in Educational Chatbots: Balancing Usability, Engagement, and Effectiveness. *Future Internet* 17, 2 (2025). doi:10.3390/fi17020064
- [2] Ana Clarissa Barroso Beleza, Suzan Evelyn Nascimento da Mota, Márcia Sampaio Lima, and Tayana Uchôa Conte. 2025. UX4ALL: A Repository of User Experience Evaluation Methods.. In *Proceedings of the XXIV Brazilian Symposium on Human Factors in Computing Systems*. SBC, Porto Alegre, RS, Brazil.
- [3] Tim Debets, Seyyed Kazem Banihashem, Desirée Joosten-Ten Brinke, Tanja E.J. Vos, Gideon Maillette de Buy Wenniger, and Gino Camp. 2025. Chatbots in education: A systematic review of objectives, underlying technology and theory, evaluation criteria, and impacts. *Computers & Education* 234 (2025), 105323. doi:10.1016/j.compedu.2025.105323
- [4] Mariana Almeida Faustino, Leo Natan Paschoal, and Pedro Henrique Valle. 2026. Instruments and Artifacts for Evaluating Educational Chatbots. In *Proceedings of the 28th International Conference on Enterprise Information Systems - Volume 2: ICEIS*. INSTICC, SciTePress, Setúbal, Portugal, 1711–1722. doi:10.5220/0014829100004018
- [5] Mohammad Amin Kuhail, Nazik Alturki, Salwa Alramlawi, and Kholood Alhejori. 2023. Interacting with educational chatbots: A systematic review. *Education and Information Technologies* 28 (2023), 973–1018.
- [6] Wari Maroengsit, Thanarath Piyakulpinyo, Korawat Phonyiam, Suporn Pongnumkul, Pimwadee Chaovalit, and Thanaruk Theeramunkong. 2019. A survey

- on evaluation methods for chatbots. In *Proceedings of the 2019 7th International conference on information and education technology*. ACM, New York, NY, USA, 111–119.
- [7] Solano Oliveira, Alexandre Cristo, Miguel Geovane, André Xavier, Roseno Silva, Sabrina Rocha, Leonardo C Marques, Genildo Gomes, Bruno Gadelha, and Tayana Conte. 2023. UXNator: A Tool for Recommending UX Evaluation Methods.. In *ICEIS (2)*. SciTePress, Setúbal, Portugal, 336–343.
- [8] Phillip Olla, Nadine Wodwaski, and Taylor Long. 2025. Beyond the Bot: A Dual-Phase Framework for Evaluating AI Chatbot Simulations in Nursing Education. *Nursing Reports* 15, 8 (2025). doi:10.3390/nursrep15080280
- [9] Leo Natan Paschoal. 2020. *A Framework to Support the Experimental Evaluation Process of the Pedagogical Conversational Systems*. Master's thesis. Universidade de São Paulo, São Carlos.
- [10] Leo Natan Paschoal. 2024. *Um framework para o planejamento de experimentos controlados na pesquisa de chatbots educacionais*. Tese (Doutorado). Universidade de São Paulo, São Carlos. doi:10.11606/T.55.2024.tde-18032025-134125
- [11] Antonella Petrillo, Mizna Rehman, and Kartikeye Awasare. 2025. Assessing the Maturity of Generative AI Systems: A Framework for Education and Public Engagement. *Procedia Computer Science* 274 (2025), 181–191. doi:10.1016/j.procs.2025.12.018 22nd International Multidisciplinary Modeling & Simulation Multiconference (I3M 2025).
- [12] Wei Qiu, Chit Lin Su, Nurabidah Binti Jamil, Maung Thway, Samuel Soo Hwee Ng, Lei Zhang, Fun Siong Lim, and Joel Weijia Lai. 2025. A Systematic Approach to Evaluate the Use of Chatbots in Educational Contexts: Learning Gains, Engagements and Perceptions. *Computers* 14, 7 (2025). doi:10.3390/computers14070270
- [13] Nicole M Radziwill and Morgan C Benton. 2017. Evaluating quality of chatbots and intelligent conversational agents. *arXiv preprint arXiv:1704.04579* (2017).
- [14] Ian Sommerville. 2016. *Software Engineering* (10 ed.). Pearson, Boston, MA, USA.
- [15] Rainer Winkler and Matthias Söllner. 2018. Unleashing the potential of chatbots in education: A state-of-the-art analysis. In *Academy of management proceedings*. Academy of Management Briarcliff Manor, NY 10510, Academy of Management, Briarcliff Manor, NY, USA, 15903.
- [16] Sebastian Wollny, Jan Schneider, Daniele Di Mitri, Joshua Weidlich, Marc Rittberger, and Hendrik Drachsler. 2021. Are We There Yet? - A Systematic Literature Review on Chatbots in Education. *Frontiers in Artificial Intelligence* Volume 4 - 2021 (2021). doi:10.3389/frai.2021.654924